

// SISTEM JE U PRODUKCIJI, NIJE DEMO

BitLab AI Asistent

4 načina korištenja · Sonnet 4.6 · praćenje svakog razgovora · brzi deploy bez prekida

62
AUTOMATSKA TESTA

41
PITANJA U TEST SETU

100%
TAČNOST NA SONNETU


7
STRANICA U DASHBOARDU

Sesija 8 → Sesija 9
poređenje više AI modela ove sedmice

// 02 • ŠTA JE SISTEM

Šta je sistem, na jednom dijagramu.

Jedan AI mozak, četiri ulaza za korisnika, jedno mjesto gdje pratimo sve što se dešava.



RAZUMIJEVANJE TEKSTA NA NAŠEM JEZIKU • LOKALNO, BEZ
SLANJA VANI

SVAKI RAZGOVOR SE PAMTI – MOŽE SE PONOVO
POGLEDATI

SONNET 4.6 KAO PODRAZUMIJEVANI
MODEL

AI ČITA ODGOVOR NAGLAS – PRIRODAN
GLAS

// 03 · GLAVNA PREDNOST

Vidimo svaki korak razgovora.

AI nije crna kutija — možemo otvoriti bilo koji razgovor i tačno vidjeti šta je AI uradio, koliko je trajalo i koliko je koštalo.

5s

AUTOMATSKO
OSVJEŽAVANJE

korak \$ · ms

PO KORAK

CIJENA I
BRZINA

ai.bitlab.rs/admin/sessions/9c4f...21ab

Bearer ✓

OBSERVABILITY

Sessions

Requests

Tool calls

Compare

Stats

CATALOG

Products

FAQ

SESSIONS · 47 total

LIVE · 5S

9c4f...21ab WIDGET 14 turns

"Imate li lapatovoe za do 2000KM..."

↓ 13.8k ↑ 0.26k \$0.045 17.2s

7a31...0e94 VOICE 6 turns

"Trebam tastaturu mehaničku do 200KM"

↓ 4.2k ↑ 0.18k \$0.013 6.5s

b88e...5fc2 EMAIL 2 turns

"Pozdrav, da li je proizvod 12345 dostupan..."

↓ 1.1k ↑ 0.09k \$0.004 3.1s

1f42...a907 WIDGET 9 turns

"Koja je razlika između IPS i VA..."

3d77...cc18 WIDGET 3 turns

5e09...4b71

9c4f...21ab · widget · started 17:42:09 UTC

USER · turn 03

"Imate li lapatovoe za do 2000KM, treba mi za faks"

▶ tool_use search_products · id: tu_01J9... 312ms

{ "query": "laptop", "category_id": "98", "max_price": 2000, "top_k": 5 }

→ 5 results · cat 98 hard filter applied

ASSISTANT · sonnet-4-6 · 1 tool call · 1142ms

"Pronašao sam 5 laptopa do 2000 KM, pogodnih za studiranje. Evo top 3..."

↓ 8.4K TOK ↑ 142 TOK \$0.0289

TIMELINE · 14 turns · 17.2s total

■ user ■ tool ■ assistant

- LIJEVO: SPISAK RAZGOVORA — JEDAN RED, JEDNA SESIJA
- SREDINA I DESNO: KOMPLETAN RAZGOVOR + BRZINA, BROJ RIJEČI, CIJENA
- KLIK NA PORUKU — VIDI TAČNO ŠTA JE AI PROVJERIO
- OVAKVOG UVIDA NIKO DRUGI U REGIJI NEMA

// 04 • KAKO AI BIRA PROIZVOD

AI odmah pogodi kategoriju u kojoj traži.

Umjesto da prvo pita „šta tražiš“ pa onda pretražuje, sistem to radi u jednom potezu — brže i tačnije.

01 AI sam bira kategoriju

JEDAN POZIV

AI dobija spisak svih 30 kategorija. Kad korisnik napiše „*treba mi laptop do 2000 KM*“, AI u jednom potezu bira kategoriju **Laptopi** i pokreće pretragu unutar nje.

02 Bogaćenje pretrage unaprijed

JEDNOM • PRI BUILD-U

Svakom proizvodu uz naziv dodajemo i sinonime kojima ga ljudi traže — *tastatura, kibord, keyboard*. Pretraga ih nalazi i kad korisnik napiše drugačije.

03 Rezerva ako AI promaši kategoriju

REZERVA

Ako AI iz nekog razloga ne pošalje kategoriju, sistem sam podigne na vrh proizvode iz prave kategorije po ključnim riječima. Korisnik nikad ne vidi pad kvaliteta.

```
● ● ● TOOLS.PY • SEARCH_PRODUCTS_SCHEMA

{
  "name": "search_products",
  "description": "Pretraga kataloga. Kategorije:
    98 = Laptopi • 12 = Monitori • 47 = Tastature
    ... (30 ukupno) ...",
  "input_schema": {
    "properties": {
      "query": { "type": "string" },
      "category_id": {
        "type": "string",
        "enum": ["98", "12", "47", ...] ← hard list
      },
      "max_price": { "type": "number" },
      "top_k": { "type": "integer" }
    }
  }
}
```

REZULTAT NA TEST SETU

41/41

SONNET • 100%

34/36

HAIKU • 94.4%

5

TESTOVI ZA
TIPFELERE

// 05 • ZAŠTO SONNET, NE HAIKU

Prešli smo sa Haiku-a 4.5 na Sonnet.

Isti zadatak, isti test — razlika je u tome *koliko mu možemo vjerovati*, ne u procentima na papiru.

● ● ● ● HAIKU-4-5 • PRODUCTION • TURN 03-04

user \$ Imate li lapatovoe

[no tool call • model asks for clarification]

ai Možete li pojasniti? Mislite li na laptop ili lapto kao dio uređaja?

user \$ Laptop

[no tool call • still]

ai Nažalost, trenutno nemamo dostupnih laptopa u katalogu.

⚠ HALUCINACIJA
catalog ima 50 laptopa u cat 98
Nije promptable bug – model ne sluša pravila pouzdano.

● ● ● ● SONNET-4-6 • ISTI PROMPT

user \$ Imate li lapatovoe

[tool_use]
search_products(
 query="laptop",
 category_id="98"
)
→ 5 laptopa • cijene • linkovi

ai Pronašao sam 5 laptopa u našem katalogu. Evo top 3 prema cijeni i ocjeni...

✓ 41/41 eval
✓ 6/6 typo regression
"lapatovoe", "lpatop", "labtop"
"laptov", "noutbuk", "ntbk"

CIJENA PO PITANJU

~3×

viša od Haikua

BRZINA ODGOVORA

~2×

sporiji od Haikua

MJESEČNI TROŠAK

+ \$1.20

na 1.000 razgovora

ODLUKA

Bolji odgovor je važniji od niže cijene. Ove sedmice testiramo i druge modele — ako neki bude jednako dobar i jeftiniji, prelazimo.

ODLUKA IZ SESIJE 7 • 22.04.2026.

05 / 11

// 06 • ŠTA JE PUKLO I ŠTA SMO POPRAVILI

6 problema sa demoa, 6 testova da se ne ponove.

Svaki red u tabeli je jedan sat live demoa koji se više ne može ponoviti.

PROBLEM NA DEMOU	ŠTA SMO URADILI	TEST	STATUS
AI čita cijenu "1.936 KM" kao "jedna marka"	Posebno pravilo za čitanje brojeva na našem jeziku — tačka se ne čita, hiljade idu kako treba	11 primjera	RIJEŠENO
Tehničke oznake (npr. <voice>) prikazuju se korisniku	Čišćenje na dva mjesta — i u backendu i u widgetu, da nikad ne procuri	7 testova	RIJEŠENO
Tabele se prikazuju kao niz crta	AI više ne piše tabele, nego daje listu — čita se i u chatu i naglas	4 testa	RIJEŠENO
Slika ne učitava za 7.2% kataloga	Skripta koja popisuje proizvode bez slike + AI ih ne preporučuje dok se ne sredi	5 testova	RIJEŠENO
AI tvrdi „Prodajni tim je obaviješten“ a u stvarnosti niko ništa nije dobio	Sad zaista šalje email — ili pošteno kaže korisniku da to ne može uraditi	ručno	PROVJERENO
Sistem padne kad se potroši kredit kod AI provajdera	Korisnik dobije ljudsku poruku, ne tehničku grešku; nas obavještava dashboard	ručno	PROVJERENO

62

AUTOMATSKI TESTOVI

41

PITANJA U TEST SETU

10

TESTOVA ZA WIDGET

113

UKUPNO • PROLAZI PRIJE SVAKOG DEPLOYA

Modele biramo na osnovu rezultata, ne osjećaja.

Upišeš pitanje, izabereš dva ili više modela — sistem ih pokreće paralelno i pokazuje brzinu, cijenu i odgovor jedan pored drugog.

ai.bitlab.rs/admin/compare2 modela rade paralelno

PITANJEimate li tastaturu

KANAL: CHAT

▶ POKRENI

● Haiku 4.5ANTHROPIC200 OK

6.5s

BRZINA

↓9.4k

UŠLO RIJEČI

↑215

IZAŠLO RIJEČI

\$0.0105

CIJENA

▶ AI je provjerio katalog – 1 poziv

pretraga("tastatura")

"Imamo 14 tastatura na zalihama. Evo 5 najpopularnijih po cijeni..."

● Sonnet 4.6PODRAZUMIJEVANI200 OK

17.0s

BRZINA

↓13.8k

UŠLO RIJEČI

↑257

IZAŠLO RIJEČI

\$0.0454

CIJENA

▶ AI je provjerio katalog – 2 poziva (pokušaj + dodatno suzio)

pretraga("tastatura", kategorija="Tastature")

pretraga("mehanička tastatura", ...)

"Pronašao sam 14 tastatura, od kojih 6 mehaničkih. Trebate li za gaming, office ili putovanje?"

→ Dodavanje novog modela je unos u tabelu – ne treba dirati kod, ne treba novi deploy.

posljednji test • 29.04.2026.

// 08 • TEHNOLOGIJE I DEPLOY

Stack i kako puštamo u rad.

Standardne, dosadne stvari (na dobar način). Svaki release ide u svoj folder — prebacivanje između verzija je trenutno i bez prekida.

BACKEND (SISTEM KOJI MISLI)

- 01 **Python + FastAPI** — standardna i provjerena kombinacija
- 02 **Lokalna baza** — sve poruke i troškovi se zapisuju, možemo se vratiti na bilo koji razgovor
- 03 **Sonnet 4.6** kao podrazumijevani AI — možemo prebaciti na drugi bez promjene koda
- 04 **Razumijevanje našeg jezika** radi lokalno na našem serveru — niko spolja ne plaća i ne vidi katalog
- 05 **Govor (AI čita naglas)** — Azure, sa rezervnim besplatnim sistemom
- 06 **Slušanje (glas u tekst)** — Groq Whisper, sa dvije rezerve

DASHBOARD (ŠTO MI KORISTIMO)

- 01 **React** — industrijski standard za moderne dashboarde
- 02 7 stranica · prijava preko tokena · podaci se sami osvježavaju
- 03 Cijeli dashboard se učitava kao jedna mala stranica — brzo i bez čekanja

KAKO PUŠTAMO NOVE VERZIJE — BEZ PREKIDA

```
/srv/aiasistent/
├─ releases/
│   ├── 2026-04-22T08-12-04Z/
│   ├── 2026-04-26T11-04-09Z/
│   └─ 2026-04-29T17-22-41Z/ ← latest
├─ shared/
│   └─ var/
│       ├── aiasistent.db · logs/ · .env
└─ current → releases/2026-04-29T17-22-41Z/
               ↑ atomic ln -sfv

systemd · memory limit 1.5 GB · restart on-failure
nginx   · /admin/   → static dist
        · /api/     → proxy 127.0.0.1:8000
```

ŠTA ZNAČI UPDATE

Nova verzija ide u svoj folder. Sistem prebaci pokazivač na nju — korisnici ne osjete prekid. Ako nešto puca, vraćamo se na prethodnu verziju za par sekundi.

// 09 • ŠTA NAM JOŠ FALI

Šta još nije **zatvoreno**.

Iskreno: ovo nije za pitch — ovo su pitanja koja postavljam sebi svakog dana.

● HITNO • OVE SEDMICE

- ! **Provjera više AI modela** — testiramo OpenAI, Llamu i DeepSeek na istom test setu da vidimo da li možemo doći do iste kvalitete jeftinije. Odluka kraj sedmice.
- ! **Postavljanje na pravi server** — uputstvo je gotovo, fizičko puštanje na produkcionu server čeka termin.
- ! **Kompatibilnost sa webshopom** — provjeriti da se chat widget ispravno učitava na BitLab sajtu (sigurnosna pravila brauzera).

● SLJEDEĆI SPRINT • OSJEĆAJ KORIŠTENJA

- ~ **Email — nastavak razgovora** — sad svaka poruka počinje od nule. Treba prepoznati da je isti kupac pisao i prije.
- ~ **Postepeno prikazivanje odgovora** — trenutno korisnik vidi „Razmišljam...” dok cijeli odgovor ne stigne. Bolje je da se riječi pojavljuju u hodu.
- ~ **Kontrola troškova** — ograničenje koliko jedna IP adresa može pitati u toku dana, plus alarm ako mjesečni trošak premasi limit.

● NE GORI • RADITI KASNIJE

- ? **Backup baze** — automatsko pravljenje rezervne kopije nije postavljeno.
- ? **Osvježavanje kataloga u toku dana** — kako da AI „vidi“ nove proizvode kad se katalog mijenja više puta dnevno?
- ? **Automatski test svakog koda** — može li 41-pitanje test set da se pokreće nakon svake izmjene?

→ Pošteno reći šta još nije gotovo je vrjednije od lažnog osjećaja da je sve završeno.

// 10 • PLAN ZA SLJEDEĆE DVIJE SEDMICE

Sesija 9 i Sesija 10, **paralelno**.

Tehnički posao i prodajni posao se ne čekaju — idu istovremeno.

SESIJA 09 PRVA SEDMICA

Poređenje više AI modela

Anthropic, OpenAI, Meta i DeepSeek na istom test setu od 41 pitanja — da vidimo ko je najbolji za naš slučaj i po kojoj cijeni.

- Sonnet 4.6 • Haiku 4.5 • Opus 4.5
- GPT-4o-mini • GPT-4.1-mini • GPT-4o
- Llama 3.3 70B • Llama 3.1 8B (Groq)
- DeepSeek-V3

ŠTA TRAŽIMO

≥99%
tačnost, bez izmišljanja

≥4.0/5.0
ocjena na 15 stvarnih scenarija

SESIJA 10 KONTINUIRANO

Asistent kao alat za rast prodaje

AI asistent ne mora biti samo podrška. Iz hiljada razgovora znamo šta kupci pitaju — to direktno koristimo za marketing i SEO.

- 01 **Provjera konkurencije i sajta** (Comtrade, ADM, Kim Tec, Nest, WinWin) — šta oni rade bolje, gdje smo mi
- 02 **Pisanje sadržaja** — vodiči po kategorijama i odgovori na najčešća pitanja
- 03 **Vidljivost na Googleu** — lokalni katalozi, partneri, PR
- 04 **Automatske reklame** — katalog ide pravo u Google Shopping
- 05 **Asistent skuplja kontakte** — newsletter, napuštena korpa, recenzije

CILJ ZA 90 DANA

+50%
posjete sa Googlea

+20
novih sajtova koji linkuju ka nama

// VRIJEME ZA RAZGOVOR

Pitanja?

Očekujem da ćemo pričati o brzini, cijeni, sigurnosti podataka i kako će izgledati puštanje na pravi server. Imam pripremljene odgovore — ali bolje pitati nego pretpostaviti.

KONTAKT

Branislav Jovković
bjovkovic@gmail.com
github.com/bitlab/ai-asistent

DODATNA DOKUMENTACIJA

- Arhitektura sistema
- Praćenje razgovora (Sessions)
- Plan poređenja modela
- Uputstvo za puštanje na server